



COMET : Commonsense Transformers for Automatic Knowledge Graph Construction




Autorzy artykułu: Antoine Bosselut, Hannah Rashkin, Maarten Sap, Chaitanya Malaviya, Asli Celikyilmaz, Yejin Choi

Wstęp

Dotychczasowe podejścia do automatycznej konstrukcji bazy wiedzy (KB) działają w oparciu o encyklopedyczną wiedzę z dobrze zdefiniowaną przestrzenią encji i relacji. Niestety, Wiedza zdroworozsądkowa nie jest dostosowana do schematu wiązania dwóch encji przez znane relacje. Dlatego aktualne rozwiązania w problemie konstrukcji KB modelują encje jako frazy w języku naturalnym, a relacje jako dowolne koncepcje je wiążące. To podejście też ma ograniczone zastosowanie w modelowaniu wiedzy zdroworozsądkowej, ponieważ ta jest często pozostawiona w domyśle. Prezentowane podejście COMET próbuje rozwiązać ten problem przez uczenie się reprezentacji przez modele językowe dużej skali. Celem COMET jest identyfikacja nowych wierzchołków w bazie wiedzy i relacji pomiędzy nimi (zgodnych z podanym zbiorem krotek). Następnie opracowano sposób uczenia modeli NLP dużej-skali aby tworzyły krotki wiedzy zdroworozsądkowej.

Architektura COMET

COMET bazuje na architekturze modelu językowego GPT, który jest oparty na transformerze, który w zamian używa mechanizmu uwagi w wariancie multi-head. Wspomniane mechanizmy są przedstawione na poniższym diagramie i równaniach.



Rysunek 1: Architektura COMET

$$\text{ATTENTION}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

$$\text{MULTIH}(Q, K, V) = [H_1; \dots; H_b]W^O$$

$$H_i = \text{ATTENTION}(QW_i^Q, KW_i^K, VW_i^V)$$

$$\text{MULTIATTN}(h_t^{l-1}) = \text{MULTIH}(h_t^{l-1}, h_t^{l-1}, h_t^{l-1})$$

Równania 1, 2, 3, 4: Mechanizm uwagi

ATOMIC Input Template and ConceptNet Relation-only Input Template

s tokens	mask tokens	r token	o tokens
----------	-------------	---------	----------

PersonX goes to the mall [MASK] <xIntent> to buy clothes

ConceptNet Relation to Language Input Template

s tokens	mask tokens	r tokens	mask tokens	o tokens
----------	-------------	----------	-------------	----------

go to mall [MASK] [MASK] has prerequisite [MASK] have money

Rysunek 2: Wejście modelu (word + position embedding)

Proces uczenia

Dla podmiotu S i relacji R, COMET przewiduje możliwe dopełnienie O. Jako wejście podawane są wektory słów (Glove) wraz z kodowaniem pozycyjnym. Dla zbioru ATOMIC, specjalne słowo "[MASK]" oddziela podmiot od relacji i orzeczenia. Relacje to słowa w formacie "<name>". Parametry takie same jak w oryginalnym GPT. Funkcja celu: maksymalizacja log-likelihood wystąpienia słowa x(t) po słowie x(t-1).

$$\mathcal{L} = - \sum_{t=|s|+|r|}^{|s|+|r|+|o|} \log P(x_t|x_{<t})$$

Równanie 5: Funkcja celu max (warunkowy log-likelihood)

Eksperymenty

Wykonano eksperymenty na dwóch zbiorach danych: ATOMIC i ConceptNet. Pierwszy składający się z 877 tysięcy krotek opisujących społeczną wiedzę zdroworozsądkową dla danych wydarzeń (np. dla "X goes to the store" zachodzi "X needs to drive there", "to get food", itd.). Podział (710K/80K/87K). Miara jakości BLEU-2, perplexity, % wygenerowanych krotek z nową wiedzą (tabela 1) i ludzkie oceny uzyskane z Amazon Mechanical Turk (tabela 2). Wyniki na drugim zbiorze pominięte dla zwięzłości.

Model	PPL ⁵	BLEU-2	N/T sro ⁶	N/T o	N/U o
9Enc9Dec (Sap et al., 2019)	-	10.01	100.00	8.61	40.77
NearestNeighbor (Sap et al., 2019)	-	6.61	-	-	-
Event2(In)VOLUN (Sap et al., 2019)	-	9.67	100.00	9.52	45.06
Event2PERSONX/Y (Sap et al., 2019)	-	9.24	100.00	8.22	41.66
Event2PRE/POST (Sap et al., 2019)	-	9.93	100.00	7.38	41.99
COMET (- pretrain)	15.42	13.88	100.00	7.25	45.71
COMET	11.14	15.10	100.00	9.71	51.20

Tabela 1: Wartości wybranych miar dla zbioru ATOMIC

Model	Avg
9Enc9Dec (Sap et al., 2019)	45.32
Event2(In)voluntary (Sap et al., 2019)	47.93
Event2PersonX/Y (Sap et al., 2019)	46.41
Event2Pre/Post (Sap et al., 2019)	46.76
COMET (- pretrain)	49.50
COMET	56.45

Tabela 2: Średnie wyniki ludzkiej ewaluacji

Seed Concept	Relation	Generated	Plausible
X holds out X's hand to Y	xAttr	helpful	✓
X meets Y eyes	xAttr	intense	✓
X watches Y every ____	xAttr	observant	✓
X eats red meat	xEff	gets fat	✓
X makes crafts	xEff	gets dirty	✓
X turns X's phone	xEff	gets a text	✓
X pours ____ over Y's head	oEff	gets hurt	✓
X takes Y's head off	oEff	bleeds	✓
X pisses on Y's bonfire	oEff	gets burned	✓
X spoils somebody rotten	xIntent	to be mean	✓
X gives Y some pills	xIntent	to help	✓
X provides for Y's needs	xIntent	to be helpful	✓

Tabela 3: Losowo wybrane dopełnienia (novel) dla krotek ze zbioru walidacyjnego (ATOMIC)